



위 사진에서 볼 수 있듯 basic한 CNN은 Convolution operation을 수행하고 activation function과 Pooling을 지속적으로 추가하는 형태로 layer를 구성하는 Feature Extraction 파트와, 이를 flatten하여 1차원의 vector로 치환 후 Fully connected (=MLP)로 layer를 구성하는 Classification 파트, 그리고 이를 통해 predict한 vector를 softmax와 같은 function의 input으로 받아 Output Prediction을 output하는 Probabilistic Distribution 파트로 이루어져 있다. Feature Extraction part에서 이미지를 분류하거나, segmentation을 하는 등의 작업을 하기 위해 image의 특징을 추출함으로써 image를 이해하는 과정을 거친 후, Classification part에서 분류를 위한 vector를 output하고, FC layer를 제거하거나 변형함으로써 classification 이외의 CV tasks를 수행할 수 있다.

합성곱, 활성화 함수, 풀링은 모두 Feature Extraction 파트에서 나오는 알고리즘으로 이외에도 padding등의 알고리즘 등이 있으며, 최근에 나오는 발전된 CNN들은 이외에도 특정 task에 맞는 더욱 효율적이고 중요한 feature를 추출할 수 있도록 추가적인 알고리즘을 구현한다. (e.g. RED-CNN)

합성곱(convolution)은 이미지의 특징을 추출하는 연산으로 필터가 입력 이미지 위를 슬라이딩하면서 operation을 통해 locality한 input 정보를 취합하고, 이를 통해 특징 맵(Feature Map)을 생성한다. Filter의 채널 수, 크기 등은 모두 hyperparameter이며, 각각의 filter들은 이미지의 예지, 색상, 질감, 형태 등 다양한 특징을 학습한다. 이런 방식으로 CNN은 이미지의 공간적인 구조를 이해하고, 복잡한 패턴까지 인식하게 된다.

활성화 함수(activation function)는 각 뉴런의 출력 값을 결정하는 비선형 함수로, 신경망이 복잡한 문제를 풀 수 있도록 해주며, CNN에서 가장 널리 사용되는 활성화 함수는 ReLU(Rectified Linear Unit)이다. ReLU는 함수 특성상(편미분 값의 일정성) Gradient Vanishing을 완화해주며, 이의 문제점들을 개선한 Leaky ReLU, ELU등도 있다.

풀링(pooling)은 CNN에서 사용하는 중요한 기법 중 하나로, parameter의 추가 없이 receptive field를 키움으로써 NN의 복잡도를 줄이고, 과적합을 방지한다. Pooling은 입력 데이터의 크기를

줄이거나 다운 샘플링하는 과정으로 이동 불변성(Translation Invariance)을 제공하여 모델이 덜 민감하게 만드는 효과도 있다. (=과적합 방지) 완전연결층은 MLP와 거의 동일하며, FE part에서 해석한 image의 특성들을 종합하여 최종적인 task를 수행하는 역할을 한다. (e.g. output class probability)